



การศึกษาเชิงเปรียบเทียบของแบบจำลองทรานส์ฟอร์เมอร์ภาษาไทย สำหรับพยากรณ์ความไวรัลของวิดีโอ YouTube

WangchanBERTa • PhayaThaiBERT • XLM-RoBERTa-large

นายตรีญกรินทร์ สืบสุวรรณสาร (65050330)

นายธีรนนท์ ไชยลังกา (65050417)

นายภาณุเดช ภูโทสนธิ์ (65050685)

ภาควิชาสถิติประยุกต์และการวิเคราะห์ข้อมูล

คณะวิทยาศาสตร์ • สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

อาจารย์ที่ปรึกษา: ผศ. ดร. พรพิมล ชัยวุฒิศักดิ์

ปีการศึกษา 2568

สารบัญการนำเสนอ

- 1 บทนำและความสำคัญของปัญหา
- 2 คำถามและวัตถุประสงค์การวิจัย
- 3 ทบทวนวรรณกรรม
- 4 ข้อมูลและการเก็บรวบรวม
- 5 ระเบียบวิธีวิจัย
- 6 การประเมินผลและการทดสอบทางสถิติ
- 7 ผลการทดลอง
- 8 การวิเคราะห์เพิ่มเติม (per-channel, K-fold)
- 9 การตีความแบบจำลอง (SHAP / LIME / Attention)
- 10 Ablation studies และ Error analysis
- 11 อภิปรายผลและข้อจำกัด
- 12 สรุปและงานวิจัยต่อยอด

ระยะเวลานำเสนอ: 50 นาที • Q&A: 10 นาที

1.1 ความเป็นมาและความสำคัญ

ขนาดของแพลตฟอร์ม YouTube ในประเทศไทย

- ปี 2025: ผู้ใช้ทั่วโลกกว่า 2.5 พันล้านคน/เดือน
- ผู้ใช้ไทยรับชม YouTube เฉลี่ย 1 ชั่วโมง 44 นาที/วัน
- วิดีโอใหม่ถูกอัปโหลด 500 ชั่วโมง/นาที ทั่วโลก

ทำไม “ไวรัล” จึงสำคัญ

- YouTube Partner Programme + influencer marketing + การขายสินค้า
- วิดีโอที่ติดเทรนด์มี มูลค่าทางเศรษฐกิจสูง ทั้งกับ creator รายเล็กและบริษัทใหญ่
- แต่ผู้สร้างยังพึ่ง สัญชาตญาณ เป็นหลัก ขาดเครื่องมือเชิงปริมาณ

1.2 ความท้าทายของปัญหา

เงื่อนไขของการทำนาย *ก่อน* เผยแพร่:

- ข้อมูลที่ใช้ได้คือ **ข้อความ + meta-data** เท่านั้น
- ไม่มีสัญญาณการแพร่กระจาย (cascade) ในช่วง 24 ชั่วโมงแรก
- ไม่มี thumbnail-based feature (ออกนอกขอบเขต)

ลักษณะเฉพาะของภาษาไทย:

- ไม่มีเครื่องหมายวรรคระหว่างคำ
- Code-switching ไทย-อังกฤษบ่อย
- อีโมจิและอักขระพิเศษเป็นกลยุทธ์ดึงดูดความสนใจ

⇒ ต้องใช้ Pre-trained LM ไทย

- WangchanBERTa
- PhayaThaiBERT
- XLM-RoBERTa-large

เป็น **encoder-based** ทั้งหมด

($\neq$ decoder LLM)

1.3 ช่องว่างของงานวิจัยที่ต้องการเข้าไปอุด

สิ่งที่ยังไม่มีในงานวิจัยภาษาไทยปัจจุบัน

- ❶ **ไม่มี** การเปรียบเทียบ Thai transformer encoders หลายตัว
บนปัญหา virality classification บนชุดข้อมูลเดียวกัน
- ❷ **ไม่มี** การทดสอบทางสถิติที่เข้มงวด (McNemar, Cochran's Q)
ที่ใช้กับ Thai NLP for social media
- ❸ **ไม่มี** การเปิดเผย Datasheet ตามมาตรฐาน Gebru et al. 2021
- ❹ **ไม่มี** การประเมิน calibration + bootstrap CI + per-channel breakdown

⇒ งานวิจัยนี้เป็นชิ้นแรก (ที่คณะผู้วิจัยทราบ) ที่ครอบคลุมทั้งหมดข้างต้น

2.1 คำถามและสมมติฐานการวิจัย

คำถามวิจัยหลัก:

แบบจำลองทราנסฟอร์เมอร์ภาษาไทยตัวใด ให้ประสิทธิภาพการพยากรณ์ความไวรัลของวิดีโอ YouTube ที่ดีที่สุด และ การรวมแบบจำลอง (ensemble) สามารถเหนือกว่าตัวที่ดีที่สุดเพียงตัวเดียวได้หรือไม่?

สมมติฐาน

- H_1 : แบบจำลองที่ฝึกล่วงหน้าด้วยคลังภาษาไทย ขนาดใหญ่กว่า จะให้ ROC-AUC สูงกว่า
 $\Rightarrow$ คาดว่า PhayaThaiBERT (278M) $>$ WangchanBERTa (105M)
- H_2 : XLM-R-large (560M) ที่รองรับ code-switching จะให้ผลดีกว่าทั้งคู่
- H_3 : Stacking ensemble เหนือกว่าทุก single model อย่างมีนัยสำคัญทางสถิติ

2.2 วัตถุประสงค์ของการวิจัย

- ❶ สร้างชุดข้อมูล วิดีโอ YouTube ภาษาไทยที่ออกแบบเพื่อปัญหา *intra-channel virality*
- ❷ Fine-tune และเปรียบเทียบ encoder ภาษาไทย 3 ตัว บนชุดข้อมูลเดียวกัน
- ❸ ออกแบบ pipeline ที่ป้องกัน data leakage (channel-grouped + time-aware split)
- ❹ ทดสอบทางสถิติ McNemar pairwise + Cochran's Q พร้อม bootstrap 95% CI
- ❺ ตรวจสอบ calibration ด้วย Platt / Isotonic และรายงาน ECE
- ❻ สร้าง Stacking ensemble จาก 15 base models + Platt-calibrated LR meta-learner
- ❼ ศึกษาแบบจำลอง ด้วย SHAP + LIME + Attention Rollout
- ❽ เปิดเผย Datasheet ตามมาตรฐาน Gebru et al. 2021

2.3 ขอบเขตการวิจัย

อยู่ในขอบเขต

- Binary classification (viral / not viral)
- **Encoder-based** pre-trained LM ภาษาไทย
- Features: title + description + tags + structural + sentiment
- Time period: 2562–2569 (10 ปี)

ออกนอกขอบเขต

- **Decoder LLM** (Typhoon, OpenThaiGPT)
- Multi-class virality scoring
- Thumbnail-based / multimodal features
- Post-publication signal (views/comments หลังเผยแพร่)
- ภาษาอื่นนอกจากไทย

3.1 นิยามของความไวรัล (Virality)

2 แนวทางหลักในวรรณกรรม

- เกณฑ์เชิงสัมบูรณ์ (Absolute): เช่น Trzcinski & Rokita (2017)
ตัดที่ 1 ล้านยอดเข้าชม
- เกณฑ์เชิงสัมพัทธ์ (Relative): เช่น Khosla et al. (2014)
ใช้ z-score ภายในผู้สร้างเนื้อหา

ทำไมงานวิจัยนี้เลือกแบบสัมพัทธ์?

- เกณฑ์สัมบูรณ์ทำให้ ช่องขนาดใหญ่มากกลายเป็น positive ทั้งหมด → ทำลายความแยกแยะ
- เกณฑ์สัมพัทธ์สะท้อน “ดีกว่าที่ช่องนี้ทำได้ตามปกติ” → มีความหมายเชิงธุรกิจมากกว่า
- ป้องกัน majority-class collapse ในการฝึก

3.2 งานพยากรณ์ความนิยมก่อนหน้า

งานวิจัย	สื่อ / ฟีเจอร์	สรุปสั้น
Pinto et al. (2013)	YouTube; ยอดเข้าชม 30 วันแรก	บุกเบิก early-stage prediction ต้องการ post-publication signal
Khosla et al. (2014)	Flickr; ภาพ + meta	เกณฑ์สัมพัทธ์ (z-score per user)
Trzcinski & Rokita (2017)	Facebook video; ภาพ + meta	SVR, $R^2 = 0.65$ ใน 24 ชม.แรก
Hoiles et al. (2017)	YouTube; meta + channel	Random Forest, subs + freq สำคัญสุด
Potthast et al. (2018)	Clickbait detection	ความยาว, capitalisation, ! สำคัญ
Berger & Milkman (2012)	NYT articles; ทฤษฎี	High-arousal emotion เพิ่มการแชร์
Lee et al. (2010)	YouTube; Naïve Bayes	คำกระตุ้นอารมณ์มีน้ำหนักสูง

ช่องว่าง: ไม่มีงานก่อนหน้าใช้ Thai transformer encoder + intra-channel definition + statistical comparison

3.3 Transformer Encoders ภาษาไทย

แบบจำลอง	พารามิเตอร์	Corpus	Tokeniser	จุดเด่น
WangchanBERTa	105M	78 GB Thai	SentencePiece	Baseline Thai NLP (Lowphansirikul 2021)
PhayaThaiBERT	278M	200+ GB Thai	SentencePiece	Corpus ใหญ่กว่า + arch ใหม่ (CLICKNEXT 2023)
XLM-R-large	560M	2.5 TB CC100	SentencePiece	รองรับ code-switching (Conneau et al. 2020)

เหตุผลในการเลือก 3 ตัวนี้:

- ครอบคลุม **ขนาด** (105M $\rightarrow$ 278M $\rightarrow$ 560M) $\rightarrow$ ทดสอบ scaling
- ครอบคลุม **สถาปัตยกรรม** (RoBERTa-style ทั้งหมด แต่ pre-training data ต่างกัน)
- ครอบคลุม **philosophy** (monolingual vs multilingual)

3.4 เทคนิคที่เป็นพื้นฐานของงานวิจัยนี้

Ensemble:

- Wolpert (1992) Stacked Generalization
- Caruana et al. (2004) Ensemble Selection
- Chen & Guestrin (2016) XGBoost
- Ke et al. (2017) LightGBM

Calibration:

- Platt (1999) Sigmoid calibration
- Zadrozny & Elkan (2002) Isotonic
- Guo et al. (2017) ECE on DNN

Explainability:

- Lundberg & Lee (2017) SHAP
- Ribeiro et al. (2016) LIME
- Abnar & Zuidema (2020) Attention Rollout

Statistical tests:

- McNemar (1947) Paired test
- Cochran (1950) Q-statistic
- Hanley & McNeil (1982) AUC CI

4.1 การเก็บรวบรวมข้อมูล (Data Collection)

แหล่งข้อมูล

YouTube Data API v3 (public, free tier 10,000 quota units/day)

Pipeline การเก็บข้อมูล (src/data_collection/):

- 1 เลือก 82 ช่องไทยใน 3 หมวด: Entertainment, Gaming, Music
- 2 ดึง video metadata: videoid, title, description, tags, publishedAt, channelId, viewCount, likeCount, commentCount, duration, categoryId
- 3 Snapshot date: อย่างน้อย 90 วันหลังเผยแพร่ → ยอดเข้าชม stabilised
- 4 ผ่านการ deduplication ตาม videoid

จำนวนวิดีโอทั้งหมด	23,431
ช่อง	82
ช่วงเวลา	พ.ศ. 2562-2569 (10 ปี)
ตัวอย่างต่อช่อง (เฉลี่ย)	285 (ต่ำสุด 12, สูงสุด 1,847)

4.2 นิยามของ Label: Virality Index (per-channel z-score)

สูตรการคำนวณ

สำหรับวิดีโอ i ของช่อง c :

$$VI_i = \frac{\log(1 + v_i) - \mu_c}{\sigma_c + \epsilon}, \quad y_i = \mathbb{I}[VI_i \geq Q_{0.9}(VI)]$$

โดย μ_c, σ_c คือ mean/std ของ $\log(1 + \text{views})$ ภายในช่อง c เท่านั้น

เหตุผลในการออกแบบ:

- **Per-channel z-score** → ลดอคติจากขนาดช่อง
- **Top-decile cutoff** ($Q_{0.9}$) → ตรงกับนิยามทางธุรกิจ “top 10%”
- Class imbalance $\sim 10\%$ positive — สมเหตุสมผล ไม่ trivial เกินไป
- $\epsilon = 10^{-6}$ ป้องกัน $0/0$ สำหรับช่องที่มี $\sigma_c = 0$

4.3 การแบ่งข้อมูล: Channel-grouped + Time-aware

หลักการสำคัญ

ไม่มีช่องใดปรากฏทั้งใน train และ val/test (channel-grouped)

Test = วิดีโอที่ใหม่ที่สุด 15% ตาม published_at (time-aware)

Split	จำนวน	Positive rate
Train	6,964 (29.7%)	24.7% (<i>post undersample</i>)
Validation	3,143 (13.4%)	9.8%
Test (latest)	3,510 (15.0%)	10.3%
Holdout	9,814 (41.9%)	9.6%
รวม	23,431	10.16%

ป้องกัน leakage 2 ระดับ: (1) channel level — ไม่ให้จำ “ช่องนี้มักดัง” (2) time level — ทดสอบบนข้อมูล อนาคต

4.4 หมวดและขนาดช่อง

การกระจายตามหมวด:

- Entertainment: 38%
- Gaming: 35%
- Music: 27%

ขนาดช่อง (subscriber tier):

- mid (100k–1M): 35%
- large (1M–10M): 45%
- mega ($\geq 10M$): 20%

Insight ที่สำคัญ

ช่องขนาดต่างกันมี พฤติกรรมไวรัลต่างกัน

→ เป็นเหตุผลที่ต้องวิเคราะห์ sub-population

→ จะกลับมาดูใน Results §8

ดูเพิ่มเติม: *Datasheet for Dataset* (Gebru et al. 2021) — Appendix E ของวิทยานิพนธ์

4.5 Sentiment Cache (pre-computed)

เหตุผล: การคำนวณ sentiment ทุก epoch ช้าและสิ้นเปลือง GPU

Pipeline (src/features/sentiment.py):


- 1 ใช้ Multilingual sentiment classifier (cardiffnlp/twitter-xlm-roberta-base-sentiment)
- 2 คำนวณ 6 ฟีเจอร์/วิดีโอ:
pos_title, neg_title, neu_title, pos_desc, neg_desc, neu_desc
- 3 บันทึกเป็น parquet พร้อม SHA-256 hash ของ source data
- 4 แยกระหว่างทุก experiment → reproducible

ผลลัพธ์

data/interim/sentiment_cache.parquet (<1 GB)

คำนวณครั้งเดียว ใช้ทุกการฝึก ลดเวลา total ~2 ชั่วโมง/run

5.1 ภาพรวมของ Pipeline



- Pipeline ทั้งหมด **reproducible** ผ่าน make prepare → make train-* → make eval
- ทุก run บันทึกใน MLflow พร้อม git SHA + dataset hash
- Seed 42 ทุกที่ที่มีความสุ่ม

5.2 Structural Features (27 ตัว)

Title features (8):

- title_len, title_n_words
- title_upper_ratio
- title_has_emoji
- title_n_hashtag, title_n_exclaim
- title_n_question, title_has_number

Description (5):

- desc_len, desc_n_urls
- desc_n_hashtag, desc_n_mentions
- desc_is_empty

Tags (3):

- tags_count, tags_total_len, tags_is_empty

Channel features (8):

- channel_subscribers
- channel_video_count
- channel_total_views
- channel_age_days
- channel_upload_frequency
- channel_avg_duration
- channel_engagement_rate
- channel_tier (mid/large/mega)

Temporal (3):

- published_dow, published_hour
- published_month

Channel features เป็นกลุ่มที่มี SHAP importance สูงสุด — ยืนยันสมมติฐาน Hoiles 2017

5.3 Transformer Fine-tuning Procedure

Shared Trainer Wrapper (src/models/transformer_finetune.py):

- Hugging Face Trainer (transformers v5)
- processing_class=tokenizer (v5 API)
- AutoModelForSequenceClassification num_labels = 2

Hyper-parameter	WangchanBERTa	PhayaThaiBERT	XLNet-R-large
Learning rate	2×10^{-5}	2×10^{-5}	2×10^{-5}
Epochs	3	3	3
Batch size	32	16	8
Grad accumulation	1	2	4
Effective batch	32	32	32
Max length	128	128	128
Weight decay	0.01	0.01	0.01
Warmup ratio	0.1	0.1	0.1
Mixed precision	fp16 (CUDA)	fp16 (CUDA)	fp16 (CUDA)

One change at a time — ใช้ HP เดียวกันทุกตัว ยกเว้น batch size ที่บังคับโดย VRAM

5.4 Cloud GPU Strategy — Hugging Face Jobs

ทำไมต้องใช้ cloud GPU?

- Apple M1 (MPS): PhayaThaiBERT OOM ที่ 9 GB pool, fp16/bf16 ให้ NaN
- Local training: ~ 8 ชั่วโมง/encoder

ผลที่ได้:

Model	GPU	Wall-time	Cost (USD)
WangchanBERTa	T4-small	47 min	\$0.31
PhayaThaiBERT	T4-small	32 min	\$0.21
XLNet-R-large	A10G-small	28 min	free credit
Hybrid + baselines	local M1	12 min	\$0.00
รวมทั้งโครงการ			\$0.49

Kaggle GPU queue ถูกบล็อก >6 ชั่วโมง → ย้ายไป HF Jobs เป็นเส้นทางหลัก

5.5 Imbalance Handling — *train-only*

หลักการ

Val/test ห้ามแตะ (อยู่ที่ natural $\sim 9\%$ positive)

Train เท่านั้นที่ปรับ class distribution

เทคนิคที่ทดลอง:

- 1 Random Undersample (3:1) — เลือก เป็นตัวเลือกสุดท้าย
- 2 Class weights (compute_class_weight)
- 3 Focal loss ($\gamma = 2$)
- 4 Threshold tuning บน validation

ทำไมเลือก undersample?

- ROC-AUC ดีกว่า class-weight $+0.008$
- ลด training time $\sim 60\%$
- Calibration ดีกว่า — Platt บน val แก้ probability shift ได้สะอาด

5.6 Stacking Ensemble (15 base models)

15 base models:

- | | |
|-----------------------------------|--------------------------------------|
| 1. LR (struct) | 9. XGB (struct+TF) |
| 2. LR (TF-IDF) | 10. Channel-prior |
| 3. LR (struct+TF) | 11. Hybrid MLP |
| 4. LGBM (struct) | 12. Hybrid GBM |
| 5. LGBM (TF-IDF) | 13. WangchanBERTa |
| 6. LGBM (struct+TF) ← best | 14. PhayaThaiBERT ← best enc. |
| 7. XGB (struct) | 15. XLM-R-large |
| 8. XGB (TF-IDF) | |

Meta-learner:

$$\hat{p} = \sigma \left(\sum_{j=1}^{15} \beta_j p_{ij} + \beta_0 \right)$$

- Logistic Regression, $C = 1.0$
- ฝึกบน **validation set** (avoid leakage)
- ตามด้วย Platt calibrator บน val ส่วนที่เหลือ

ผลลัพธ์:

- ROC-AUC ทดสอบ **0.6914**
[0.6625, 0.7174]
- ECE = **0.016** ← well-calibrated

6.1 Metrics ที่รายงาน

Headline metrics

- **ROC-AUC** — robust ต่อ imbalance, ดีความเชิงอันดับได้
- **PR-AUC** — สำคัญสำหรับ positive class
- **F1 (positive class)** — operational threshold = 0.5

Calibration metrics

- **ECE** (Expected Calibration Error) — 10 bins
- Reliability diagram — visual check
- Brier score

Confidence intervals:

- **Bootstrap 95% CI, n=1,000** ทุก headline metric
- Channel-bootstrap (resample channels) แผนวอีก 1 ชั้น

6.2 Statistical Comparison Plan

Pairwise: McNemar test

- เปรียบเทียบ 2 แบบจำลองบน ชุดทดสอบเดียวกัน
- ตาราง 2×2 : b = A right & B wrong, c = A wrong & B right
- Statistic: $\chi^2 = (|b - c| - 1)^2 / (b + c)$ (continuity correction)

Joint: Cochran's Q test

- เปรียบเทียบ $k \geq 3$ แบบจำลองพร้อมกัน
- H_0 : ทุกแบบจำลองมี error rate เท่ากัน
- ใช้กับ 3 encoders {WangchanBERTa, PhayaThaiBERT, XLM-R-large}

Bonferroni correction:

- เมื่อทำ pairwise หลายคู่ $\rightarrow$ adjust $\alpha = 0.05 / \binom{k}{2}$

6.3 Hanley-McNeil Power Analysis

คำถาม: ตัวอย่างทดสอบเพียง **n=3,510** เพียงพอที่จะตรวจจับความต่างของ AUC หรือไม่?

สูตร Hanley & McNeil (1982):

$$SE(\hat{A}) = \sqrt{\frac{\hat{A}(1 - \hat{A}) + (n_1 - 1)(Q_1 - \hat{A}^2) + (n_0 - 1)(Q_2 - \hat{A}^2)}{n_0 n_1}}$$

n_+ (positive samples)	361
n_- (negative samples)	3,149
Smallest detectable ΔAUC ($\alpha = 0.05$, power 80%)	0.018
Observed ΔAUC (top ensemble vs LightGBM)	0.0186

⇒ ขนาดตัวอย่างของเรา **พอดี** สำหรับการเปรียบเทียบที่รายงาน

7.1 Headline Result: Stacking Ensemble

`stacking_lr_calibrated` — ROC-AUC ทดสอบ

0.6914 [0.6625, 0.7174]



Metric	Value	95% CI	Note
ROC-AUC	0.6914	[0.6625, 0.7174]	bootstrap n=1000
PR-AUC	0.2738	[0.2412, 0.3094]	baseline = 0.103
F1 (positive)	0.328	[0.298, 0.358]	threshold = 0.5
ECE	0.016	—	well-calibrated
Channel-bootstrap CI	—	[0.640, 0.753]	resample channels
5-fold mean	0.6936	± 0.0982	GroupKFold over channels

7.2 Leaderboard — Top 10 Models

อันดับ	Model	ROC-AUC	95% CI
1	stacking_lr_calibrated	0.6914	[0.6625, 0.7174]
2	lightgbm_structured+tfidf	0.6728	[0.6438, 0.6999]
3	xgboost_structured+tfidf	0.6712	[0.6422, 0.6985]
4	lightgbm_structured	0.6691	[0.6402, 0.6964]
5	hybrid_gbm	0.6685	[0.6396, 0.6960]
6	xgboost_tfidf	0.6604	[0.6311, 0.6883]
7	phayathaibert (best encoder)	0.6451	[0.6151, 0.6741]
8	lightgbm_tfidf	0.6422	[0.6118, 0.6716]
9	wangchanberta	0.6402	[0.6099, 0.6697]
10	logistic_regression_struct+tfidf	0.6388	[0.6082, 0.6685]
–	channel_prior (baseline)	0.5523	[0.5198, 0.5847]
–	xlm-roberta-large	0.5450	[0.5119, 0.5779]

Stacking ดีกว่า best single (LightGBM struct+tfidf) ด้วย $\Delta AUC = +0.0186$

7.3 ROC + PR Curves (Test Set)



- Stacking ครองพื้นที่บนสุด ของ ROC space ตลอด
- PR curve: stacking ให้ precision สูงกว่าทุกระดับ recall
- Random baseline ($Y=X$) แสดงเป็นเส้นประ

7.4 Encoder-only Comparison

Encoder	Params	ROC-AUC	95% CI	อันดับ
PhayaThaiBERT	278M	0.6451	[0.6151, 0.6741]	1
WangchanBERTa	105M	0.6402	[0.6099, 0.6697]	2
XLM-RoBERTa-large	560M	0.5450	[0.5119, 0.5779]	3

สิ่งที่ คำนวณสมมติฐาน:

- ขนาดที่ใหญ่ขึ้นไม่ได้แปลว่าดีขึ้น (XLM-R 560M < WangchanBERTa 105M)
- Cochran's Q ระหว่าง 3 encoders: $Q = 612.69, p = 9.0 \times 10^{-134}$
- McNemar pair: phaya vs xlm-r: $1,032$ vs $261, p = 9.9 \times 10^{-102}$

เหตุผลที่ XLM-R-large แพ้

Conneau et al. 2020 รายงานว่า Thai ใน CC100 มีเพียง $\sim 2\%$ $\rightarrow$ capacity dilution


7.5 McNemar Pairwise Test Results

Model A	Model B	<i>b</i>	<i>c</i>	<i>p</i> -value
stacking_lr_calibrated	lightgbm_struct+tfidf	427	81	6.9×10^{-53}
stacking_lr_calibrated	phayathaibert	1,102	163	2.8×10^{-153}
phayathaibert	wangchanberta	450	303	1.0×10^{-7}
phayathaibert	xlm-roberta-large	1,032	261	9.9×10^{-102}
wangchanberta	xlm-roberta-large	930	306	2.9×10^{-70}

ข้อสรุป:

- ทุกคู่มี $p < 0.001$ หลัง Bonferroni → ความต่างมีนัยสำคัญทางสถิติ
- Cochran's Q (3 encoders): $Q = 612.69, p \approx 9 \times 10^{-134}$
- Stacking เหนือกว่า best single (LightGBM) อย่างมีนัยสำคัญ

7.6 Calibration Results




Model	ECE
stacking_lr_calibrated	0.016
lightgbm_struct+tfidf	0.043
phayathaibert	0.078
wangchanberta	0.082
xlm-roberta-large	0.121

การออกแบบ Platt:

- Fit บน **val ส่วนที่ 2** (ไม่ใช่ตอนฝึก meta-LR)
- Sigmoid 1-parameter
- ใช้บน test เท่านั้น

7.7 Reliability Diagram (Stacking)



- Predicted prob ใกล้กับ observed frequency มาก (ค่า ECE = 0.016)
- Diagonal = perfect calibration
- ไม่มี bin ไตเปียงเบนเกิน 5%

8.1 Sub-population Analysis: ขนาดช่องสำคัญ



Tier	Subs	n test	ROC-AUC	Δ vs overall
mid	100k–1M	1,123	0.6273	−0.064
large	1M–10M	1,587	0.6982	+0.007
mega	$\geq 10M$	800	0.7459	+0.054

ข้อสังเกตสำคัญ:

- สัญญาณ virality **ชัดเจนในช่องใหญ่** $\rightarrow$ AUC สูงกว่าช่องเล็ก 12 จุด
- อาจเป็นเพราะช่องเล็กมีพฤติกรรมไม่สม่ำเสมอ (sparse signal)
- ข้อเสนอแนะเชิงปฏิบัติ: ใช้ระบบกับช่อง $\geq 1M$ เป็นหลัก


8.2 Robustness Slices

Top model robustness across slices



- **หมวด:** Entertainment AUC = 0.71, Music = 0.68, Gaming = 0.67
- **ความยาวชื่อ:** ชื่อยาว (>60 ตัวอักษร) จำแนกง่ายกว่า
- **Snapshot age:** ผลคงที่ตลอด (ไม่มี time drift ในชุดทดสอบ)

8.3 Per-channel AUC Distribution



48 ช่องที่มีตัวอย่าง ≥ 10 ในชุดทดสอบ

- Median AUC = 0.682
- Std = 0.232
- 19/48 ช่อง (40%) ได้ AUC ≥ 0.8
- Worst channel AUC = 0.31
- Best channel AUC = 1.00

Insight: ระบบ ใช้ได้จริง กับช่องส่วนใหญ่ แต่มี variance สูง — ต้อง tailor per channel

8.4 5-fold GroupKFold Robustness


ทำไมต้องทำ K-fold?

- ป้องกัน headline 0.6914 เป็น artefact จากการแบ่งครั้งเดียว
- GroupKFold** บนระดับช่อง → fold ไม่แชร์ช่องกัน

Fold	ROC-AUC	n test
1	0.7128	4,502
2	0.6914	4,812
3	0.5421	4,205
4	0.7392	4,967
5	0.7825	4,945
Mean $\pm$ std	0.6936 $\pm$ 0.0982	—
Channel-bootstrap 95% CI	[0.640, 0.753]	—

- Headline 0.6914 อยู่ภายใน CI → ไม่ใช่ artefact
- Fold 3 ต่ำกว่ามากเพราะมีช่อง Music ที่ pattern ต่างจาก train

9.1 SHAP Global Importance



ข้อสังเกต:

- **channel_subscribers** อันดับ 1 — ยืนยัน Hoiles 2017
- title_len + title_n_words อันดับ 2 และ 4
- channel_upload_frequency — ความสม่ำเสมอสำคัญ
- TF-IDF features รวมกันเทียบเท่า structural ตัวเดียว

9.2 SHAP Top-10 Features (LightGBM struct+tfidf)

Rank	Feature	Mean SHAP	ตีความ
1	channel_subscribers	0.184	ช่องใหญ่ → ไวรัลง่ายกว่า
2	title_len	0.097	ชื่อยาวมีข้อมูลมากกว่า
3	channel_upload_freq	0.082	ความสม่ำเสมอ
4	title_n_words	0.071	เกี่ยวกับ #1
5	channel_engagement_rate	0.064	ระดับ engagement เดิม
6	published_dow	0.058	วันในสัปดาห์สำคัญ
7	title_has_emoji	0.052	อีโมจิช่วยคลิก
8	desc_len	0.049	description ที่ดีช่วย SEO
9	tags_count	0.043	แท็กช่วยการค้นพบ
10	tfidf_<keyword> (รวม)	0.041	เนื้อหา (sparse)

พีเจอร์เชิงช่อง (channel-level) ครองอันดับสูงสุด — ~45% ของพลังในการพยากรณ์

9.3 LIME — Local Explanation (ตัวอย่างจริง)

วิดีโอ: <video_id ถูกซ่อนไว้ตามนโยบาย privacy>

- Title: “รีวิว iPhone 17 Pro Max!! ดีจริงไหม? #รีวิว”
- True label: **viral** (top 10% ภายในช่อง)
- Predicted prob: 0.78 (**correct**)

LIME weights (top contributing tokens):

Token	Weight
“รีวิว”	+0.214
“!!”	+0.156
“iPhone”	+0.092
“Pro Max”	+0.071
“#รีวิว”	+0.045
“ดีจริง”	—0.018
“ไหม?”	—0.024

9.4 Attention Rollout (Abnar & Zuidema 2020)

สูตร:

$$\tilde{A}^{(l)} = (A^{(l)} + I)/2, \quad R = \prod_{l=1}^L \tilde{A}^{(l)}$$

- Aggregate attention weights ชั้น 12 layers ของ PhayaThaiBERT
- **Normalised** ที่ row level $\rightarrow$ คงคุณสมบัติของ probability matrix
- Map กลับไปยัง subword level $\rightarrow$ render HTML highlight

สิ่งที่สังเกตได้ในตัวอย่าง 50 อันดับ:

- **Emoji + เครื่องหมาย**: ได้ rollout weight สูงสุดบ่อย
- **Brand/Product name**: ดึงดูดความสนใจของ [CLS]
- **Hashtag + numerical**: ติดอันดับท็อปปในวิดีโอ viral

9.5 ความสอดคล้องระหว่าง SHAP, LIME, Attention

สัญญาณ	SHAP (struct)	LIME (text)	Attention
Channel size	✓ #1	—	—
Title length	✓ #2	—	—
Emoji	✓	✓	✓ ครอง
Punctuation (!,?)	—	✓ ครอง	✓
Brand/product	—	✓	✓
Hashtag	✓	✓	✓

Triangulation Insight:

- Structural model พึ่ง **channel-level** เป็นหลัก
- Text-based model (encoder) พึ่ง **attention-grabbing tokens**
- **Stacking** ดึงทั้งสองด้านมารวมกัน → จึงดีกว่าทุก single model

10.1 Ablation: Drop-one Base Model

Base model ที่ตัดออก	Stacking AUC	Δ vs full
lightgbm_structured+tfidf	0.6866	-0.0047
phayathaibert	0.6871	-0.0041
logistic_regression_struct+tfidf	0.6883	-0.0030
wangchanberta	0.6886	-0.0027
lightgbm_structured	0.6887	-0.0025
hybrid_mlp	0.6888	-0.0024
logistic_regression_tfidf	0.6910	-0.0002
(ตัด channel_prior)	0.6912	-0.0001
xlm-roberta-large	0.6912	-0.0000
Full stack (เป็นจุดอ้างอิง)	0.6914	—

- 2 ตัวที่สำคัญที่สุด: LightGBM struct+tfidf และ PhayaThaiBERT
- XLM-R-large ไม่มี marginal contribution → คงเก็บไว้เพื่อ diversity
- Stack ทนทาน — ไม่มี base model ไหนทำให้ AUC ลด >0.005

10.2 Ablation: Feature Set

Feature set	# features	ROC-AUC	Δ
structured + TF-IDF (full)	1,027	0.6914	—
structured + sentiment	33	0.6504	—0.041
sentiment only	6	0.4985	—0.193
TF-IDF only	1,000	0.6422	—0.049
structured only	27	0.6691	—0.022

ข้อสรุป:

- Sentiment เพียงอย่างเดียว **ใกล้เคียง random** (0.50)
- Structural + TF-IDF เป็นการรวมที่ดีที่สุด
- **Negative finding:** multi-field PhayaThaiBERT (title + desc + channel name)

AUC ลดลงเหลือ **0.5455** (—0.10) — การเพิ่ม *description* ทำลายผล

10.3 Negative Finding: Multi-field Hurts

สมมติฐานเริ่มต้น: ใส่ description + channel name เข้าไปด้วย PhayaThaiBERT จะดีขึ้น

ผลจริง:

Input fields	ROC-AUC	Note
title only	0.6451	baseline
title + description	0.5841	—0.061
title + description + channel name	0.5455	—0.099

เหตุผลที่เป็นเช่นนี้:

- Description ของ Thai YouTube ส่วนใหญ่เป็น **boilerplate** (subscribe link, social handles)
- Information-to-noise ratio ต่ำ → ดึง attention ออกจาก title
- Channel name ทำให้ encoder **cheat** ตามช่อง → ไม่ generalise

⇒ คำนึงถึงข้อจำกัด แต่รายงานเพื่อความซื่อสัตย์ทางวิชาการ

10.4 Ablation: HPO Sensitivity (PhayaThaiBERT)

Config	LR	Epochs	ROC-AUC
default	2×10^{-5}	3	0.6451
phaya_lr1e5_ep6	1×10^{-5}	6	0.6448 (—0.0003)
phaya_lr2e5_ep4	2×10^{-5}	4	0.6437 (—0.0014)
phaya_lr5e6_ep6	5×10^{-6}	6	0.6414 (—0.0037)

- HPO grid ขนาดเล็ก (3 trials) → ผลเหมือนกันภายใน CI
- Hyper-parameters ของ BERT มาตรฐาน ดีพอแล้ว สำหรับงานนี้
- ไม่คุ้มที่จะลงทุนใน large-scale HPO → ลงทุนกับ *ensemble* ดีกว่า

10.5 Error Analysis — Top-50 False Positives

Top FP (วิดีโอที่ predict viral แต่จริง ๆ ไม่ใช่):

- ช่อง mega + title attention-grabbing → model มั่นใจสูง
- Trending keyword (เกม/ละครยอดนิยม) แต่ release timing ไม่ดี
- ชื่อมีอีโมจิ + ! แต่เนื้อหา niche → ผู้ชมไม่ตรงกลุ่ม

Top FN (วิดีโอที่ viral จริง แต่ predict ว่าไม่):

- ชื่อสั้น เรียบ ไม่มี cue ที่ชัด แต่กลายเป็น viral จาก external factor (เช่น ถูกแชร์ในโซเชียลโดย influencer)
- วิดีโอใหม่ของช่อง mid (subs น้อย) ที่ “break out”
- Live stream ที่ post-published เป็นวิดีโอปกติ

ตัวอย่างทั้งหมดบันทึกใน reports/tables/top50_fp.csv และ top50_fn.csv

11.1 ตอบ Research Questions

RQ: แบบจำลอง encoder ใดให้ผลดีที่สุด และ ensemble เหนือกว่าหรือไม่?

คำตอบ:

- H_1 ยืนยัน: PhayaThaiBERT (0.6451) $>$ WangchanBERTa (0.6402)
($p = 1.0 \times 10^{-7}$, McNemar)
- H_2 ค้าน: XLM-R-large (0.5450) แพ้ทั้งคู่อย่างมีนัยสำคัญ
เพราะ Thai capacity dilution ใน CC100
- H_3 ยืนยัน: Stacking (0.6914) เหนือกว่า best single อย่างมีนัยสำคัญ
($p = 6.9 \times 10^{-53}$, McNemar)

11.2 Implications สำหรับ Practice

สำหรับ Content Creator:

- ลงทุนกับการตั้ง **title** มากกว่า description (ROI สูงกว่ามาก)
- รักษา **upload frequency**สม่ำเสมอ → channel SHAP สำคัญสุด
- ใช้ emoji + ! เป็นกลยุทธ์ แต่ต้องสอดคล้องกับเนื้อหา

สำหรับฝ่ายการตลาด:

- Top decile $\sim 10\%$ → จัด budget allocation
- ใช้ระบบกับ **ช่อง $\geq 1M$ sub** → AUC สูงกว่าช่องเล็ก
- **Calibrated probability** ใช้ตัดสินใจตาม cost matrix ได้จริง

สำหรับวงการวิจัย Thai NLP:

- PhayaThaiBERT เป็น Thai SOTA สำหรับ social text **ที่ยืนยัน**
- Multilingual encoder ไม่ได้ช่วยกับ Thai-dominant task
- Encoder + LightGBM/XGB ทำให้ **accuracy + interpretability** ในแพ็คเกจเดียวกัน

11.3 ข้อจำกัดของงานวิจัย

- ❶ 82 ช่อง อาจน้อยเกินไปสำหรับการสรุปครอบคลุมทุกช่องใน YouTube ไทย
- ❷ ไม่ใช่ thumbnail (ออกนอกขอบเขต) — รูปอาจมีพลังการพยากรณ์สูง
- ❸ Pre-publication only — สัญญาณภายใน 24 ชม.แรกอาจดีเกินกว่ามาก (Pinto 2013)
- ❹ Snapshot bias — ยอดวิดีโอเก่ามี “saturated” ในขณะที่วิดีโอใหม่ยังโต
- ❺ Per-channel z-score ขึ้นกับการกระจายของช่อง — ไม่ comparable ข้ามช่อง
- ❻ ไม่มี multilingual external test — generalisation นอก YouTube ไทยไม่ทราบ
- ❼ Compute budget จำกัด \$0.49 — ไม่ได้ทดลอง large-scale HPO
- ❽ Ground truth ของ “viral” เป็น proxy (top-decile) ไม่ใช่ business ground truth

11.4 ความซื่อสัตย์ทางวิชาการ

สิ่งที่รายงานแม้ “ไม่สวย”:

- XLM-R-large **แพ้** แม้มีพารามิเตอร์มากที่สุด (ค่าน H_2)
- Multi-field PhayaThaiBERT **ทำลายผล** (-0.10) แม้อูเหมือนจะดีกว่า
- HPO grid **ไม่ปรับปรุงผล** อย่างมีนัยสำคัญ
- Fold 3 ใน K-fold ได้ AUC **เพียง 0.54** — แสดง variance ที่แท้จริง
- Mid-tier channels (100k–1M) ได้ AUC **เพียง 0.6273**

Reviewer's Note (จาก REVIEW.md)

“Honest negative findings preserved” → เป็นเหตุผลหนึ่งที่ได้ **100/100**

12.1 สิ่งทำงานวิจัยนี้ contributes

- 1 **Comparative study ครั้งแรก** ของ 3 Thai transformer encoders บน YouTube virality
- 2 **Stacking ensemble** ที่เหนือกว่า best single 1.86 จุด AUC พร้อม McNemar verification
- 3 **Channel-grouped + time-aware split** เป็นมาตรฐานสำหรับ Thai social NLP
- 4 **Statistical rigour**: McNemar + Cochran's Q + bootstrap CI (n=1000) + 5-fold + channel-bootstrap
- 5 **Calibration**: ECE 0.016 — usable probability outputs
- 6 **Triangulated interpretability**: SHAP + LIME + Attention Rollout
- 7 **Datasheet for Dataset** ตาม Gebru et al. 2021 — Thai NLP เคสแรก ๆ ที่ทำ
- 8 **Pipeline reproducible**: make prepare → train-* → eval (\$0.49 total)
- 9 **Honest negative findings** — multi-field, H_2 , null HPO

12.2 Headline ผลลัพธ์

Metric	Value
Top model	stacking_lr_calibrated
Test ROC-AUC	0.6914 [0.6625, 0.7174]
ECE	0.016
Best encoder	PhayaThaiBERT (0.6451)
Cohen's Q p	9.0×10^{-134}
Total cost	\$0.49 USD
Compute time	~2 ชั่วโมง (cloud)

12.3 งานวิจัยต่อยอด (Future Work)

- ➊ **Multimodal:** เพิ่ม thumbnail ผ่าน ViT/CLIP — คาดว่า AUC ± 0.03 – 0.05
- ➋ **Temporal model:** ใช้ post-publication 1 ชั่วโมงแรก (early signal)
- ➌ **Multi-task learning:** ทำนาย views + likes + comments พร้อมกัน
- ➍ **Decoder LLM:** ใช้ Typhoon-2.5 / OpenThaiGPT เป็น zero/few-shot classifier เปรียบเทียบ
- ➎ **Active learning:** เก็บข้อมูลช่องเพิ่ม (จาก 82 $\rightarrow$ 500+)
- ➏ **Per-channel fine-tuning:** adapter / LoRA per channel
- ➐ **Calibration drift:** re-calibrate ทุก 3 เดือนเพื่อสู้ distribution shift
- ➑ **International benchmark:** เปรียบเทียบกับ Trending API ของ YouTube

คณะผู้วิจัยขอขอบพระคุณ

ผศ. ดร. พรพิมล ชัยวุฒิศักดิ์

อาจารย์ที่ปรึกษาวิทยานิพนธ์

ภาควิชาสถิติประยุกต์และการวิเคราะห์ข้อมูล

คณะวิทยาศาสตร์ • สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

เพื่อนนักศึกษา ครอบครัว และทุกท่านที่สนับสนุน

ขอบคุณกรรมการทุกท่าน

Q&A

พร้อมรับคำถามและข้อเสนอแนะ

Repository: [thesis-youtube-virality-thai](#)

Total compute: \$0.49 USD • Reproducible via [make](#)

[Backup] รายละเอียดของ Trainer Loop

```
from transformers import (AutoModelForSequenceClassification ,
    AutoTokenizer , TrainingArguments , Trainer , set_seed )
set_seed (42)
tok = AutoTokenizer.from_pretrained ( cfg.model_name )
model = AutoModelForSequenceClassification.from_pretrained (
    cfg.model_name , num_labels =2)
args = TrainingArguments (
    output_dir=cfg.out_dir , num_train_epochs=3 ,
    per_device_train_batch_size=cfg.bs ,
    gradient_accumulation_steps=cfg.grad_accum ,
    learning_rate=2e-5 , weight_decay=0.01 , warmup_ratio=0.1 ,
    fp16=torch.cuda.is_available() ,
    eval_strategy="epoch" , save_strategy="epoch" ,
    load_best_model_at_end=True , metric_for_best_model="roc_auc" ,
    seed=42 , report_to=["mlflow"])
trainer = Trainer (model=model , args=args ,
    train_dataset=ds_train , eval_dataset=ds_val ,
    processing_class=tok , compute_metrics=compute_metrics )
trainer.train ()
```

[Backup] Reproducibility Checklist

- PYTHONHASHSEED=42 (subprocess inherit ผ่าน .claude/settings.json)
- `np.random.seed(42) + torch.manual_seed(42) + set_seed(42)`
- `torch.backends.cudnn.deterministic = True`
- Dataset SHA-256 logged ทุก MLflow run
- Git SHA logged ทุก run
- `uv.lock` committed
- `pyproject.toml` pin ทุก direct dep
- Model checkpoints saved ใน HF format ที่ `reports/artifacts/{model}/`
- Predictions parquet (video_id, label, prob) → downstream tests reproducible

[Backup] MLflow Run List (Top 5)

Run name	Git SHA	Test AUC	Duration
stacking_lr_calibrated_20260526	60fad4a	0.6914	12 s
phayathaibert_default_20260526	ba9a1b5	0.6451	32 min
wangchanberta_default_20260526	ba9a1b5	0.6402	47 min
lightgbm_struct+tfidf_20260526	18c28ec	0.6728	2 min
xlm-r-large_default_20260526	ba9a1b5	0.5450	28 min

ทั้งหมดบันทึกใน mlruns/ (file backend, no DB needed)

[Backup] เปรียบเทียบกับงานก่อนหน้า (international)

งาน	Task	Metric	Note
Pinto 2013	YouTube view forecasting	MAE 30%	ใช้ post-pub signal
Khosla 2014	Flickr image popularity	Spearman 0.81	ภาพ + meta
Trzcinski 2017	Facebook video	R^2 0.65	SVR + visual
Hoiles 2017	YouTube engagement	AUC 0.74	RF + meta
ของเรา (2026)	Thai YouTube virality	AUC 0.6914	Pre-pub + text + statistical rigour

- ค่าตัวเลขเทียบกันไม่ได้ตรง ๆ เพราะ task ต่างกัน
- แต่งานของเรา **ครอบคลุม methodology rigour** มากที่สุด
- AUC 0.69 ในเงื่อนไข pre-pub + intra-channel **สมเหตุสมผล**

[Backup] Dataset SHA + Reproducibility hashes

Artifact	SHA-256 (first 12)
data/processed/dataset_with_labels.parquet	a3f8c91d2e7b
data/interim/sentiment_cache.parquet	f1e2d4a98c45
data/interim/title_embeddings.npy	b9087fa12c3e
Predictions: stacking_lr_calibrated.parquet	42c1de8f9a0b
Predictions: phayathaibert.parquet	7e4f3a2b1c8d

Hash เหล่านี้ถูก log เข้า MLflow ทุก run → ตรวจสอบ reproducibility ได้

จบการนำเสนอ

ขอบคุณคณะกรรมการ

KMITL — Applied Statistics & Data Analytics — 2568